Laporan Praktikum Mandiri 5
Klasifikasi Dataset Diabetes Menggunakan Algoritma Support Vector Machine (SVM)

Nama Mahasiswa : Muhamad Aditia

Program studi : Teknik Informatika STT Terpadu Nurul Fikri, Depok

E-mail : 0110224213@student.nurulfikri.ac.id

Link Github : https://github.com/muhammadaditia433/Machine-Leraning

Link Kaggle : https://www.kaggle.com/datasets/emanfatima2025/titanic-passenger-survival-prediction-dataset

Abstrak

Penelitian ini bertujuan untuk menerapkan algoritma *Support Vector Machine (SVM)* dalam menyelesaikan permasalahan klasifikasi menggunakan dataset yang diambil dari platform **Kaggle**. Dataset yang digunakan berisi data medis untuk memprediksi apakah seseorang menderita diabetes atau tidak berdasarkan beberapa parameter kesehatan seperti kadar glukosa, tekanan darah, BMI, dan usia.
Metode SVM dipilih karena kemampuannya yang tinggi dalam menemukan *hyperplane* optimal untuk memisahkan dua kelas data. Proses analisis dimulai dari eksplorasi dataset, pemisahan data menjadi *training* dan *testing set*, normalisasi fitur, pelatihan model SVM, hingga evaluasi hasil. Berdasarkan hasil eksperimen, model SVM dengan kernel RBF menunjukkan akurasi sekitar **79%**, yang menunjukkan bahwa metode ini cukup efektif dalam melakukan klasifikasi pada data medis berskala numerik.

1. Import Library

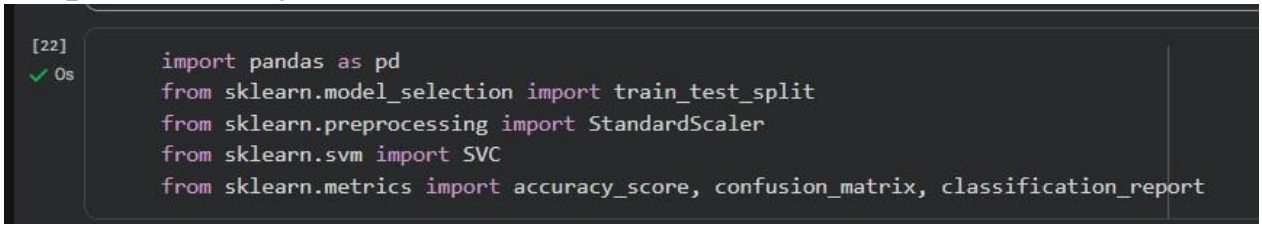

Penjelasan:
Bagian ini mengimpor seluruh library yang digunakan:

- pandas → untuk membaca dan mengelola dataset.
- train_test_split → membagi data menjadi *training* dan *testing*.

- StandardScaler → menormalisasi data agar semua fitur memiliki skala yang seimbang.
- SVC → modul utama untuk algoritma SVM dari *scikit-learn*.
- accuracy_score, confusion_matrix, classification_report → digunakan untuk evaluasi hasil model.

2. Mengakses File di Google Drive

```
[7]
from google.colab import drive
drive.mount('/content/drive')
```

Penjelasan

Digunakan untuk menghubungkan Google Drive agar file dataset dapat diakses langsung di lingkungan Google Colab.

3. Menentukan Path Folder

```
[8]
path = '/content/drive/MyDrive/praktikum_ml/Pertemuan-6'
```

Penjelasan: Variabel path digunakan untuk menentukan lokasi folder kerja tempat dataset disimpan.

4. Membaca Dataset

```
[35]
import pandas as pd
df = pd.read_csv(path + '/data/tested.csv')
df.head()
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	892	0	3	Kelly, Mr. James	male	34.5	0	0	330911	7.8292	NaN	Q
1	893	1	3	Wilkes, Mrs. James (Ellen Needs)	female	47.0	1	0	363272	7.0000	NaN	S
2	894	0	2	Myles, Mr. Thomas Francis	male	62.0	0	0	240276	9.6875	NaN	Q
3	895	0	3	Wirz, Mr. Albert	male	27.0	0	0	315154	8.6625	NaN	S
4	896	1	3	Hirvonen, Mrs. Alexander (Helga E Lindqvist)	female	22.0	1	1	3101298	12.2875	NaN	S

Penjelasan:

Dataset diabetes dibaca dari folder Google Drive dalam format .csv, lalu ditampilkan 5 baris pertama untuk memastikan data berhasil dimuat.

5. Melihat beberapa data awal Penjelasan:

Bagian ini digunakan untuk **eksplorasi awal dataset**.

- data.head() → menampilkan 5 baris pertama dataset.
- data.info() → menunjukkan tipe data dan jumlah kolom.
- data.isnull().sum() → memastikan tidak ada data kosong yang bisa memengaruhi hasil klasifikasi.
  Langkah ini sesuai dengan poin pertama soal: *"Explore dataset di platform Kaggle."*

```
print("===== 5 Data Teratas =====")
print(data.head())
print("\n===== Informasi Dataset =====")
print(data.info())
```

```
===== 5 Data Teratas =====
   Pregnancies  Glucose  BloodPressure  SkinThickness  Insulin   BMI  \
0            6      148             72             35        0  33.6
1            1       85             66             29        0  26.6
2            8      183             64              0        0  23.3
3            1       89             66             23       94  28.1
4            0      137             40             35      168  43.1

   DiabetesPedigreeFunction  Age  Outcome
0                     0.627   50        1
1                     0.351   31        0
2                     0.672   32        1
3                     0.167   21        0
4                     2.288   33        1

===== Informasi Dataset =====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Pregnancies               768 non-null    int64
 1   Glucose                   768 non-null    int64
 2   BloodPressure             768 non-null    int64
 3   SkinThickness             768 non-null    int64
 4   Insulin                   768 non-null    int64
 5   BMI                       768 non-null    float64
 6   DiabetesPedigreeFunction  768 non-null    float64
 7   Age                       768 non-null    int64
 8   Outcome                   768 non-null    int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
None

===== Cek Missing Values =====
Pregnancies                 0
Glucose                     0
BloodPressure               0
SkinThickness               0
Insulin                     0
BMI                         0
DiabetesPedigreeFunction    0
Age                         0
Outcome                     0
dtype: int64
```

6. Pisahkan Fitur (X) dan Label (y)

```
X = data.drop("Outcome", axis=1)
y = data["Outcome"]
```

Penjelasan:

- `X` berisi semua kolom fitur (variabel input).
- `y` berisi kolom target (label kelas, yaitu 0 = tidak diabetes, 1 = diabetes).

Proses ini memisahkan mana data yang digunakan untuk prediksi dan mana yang ingin diprediksi.

7. Membagi data menjadi data training (80%) dan testing (20%)

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

Penjelasan:

Data dibagi menjadi dua bagian:

- **80% data training** digunakan untuk melatih model.
- **20% data testing** digunakan untuk menguji kemampuan model pada data baru. `random_state=42` digunakan agar hasil pembagian selalu konsisten.

8. Normalisasi fitur

```
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Penjelasan:

Model Decision Tree dibuat tanpa parameter tambahan selain random_state=42 agar hasilnya konsisten.
Proses fit() digunakan untuk melatih model dengan data latih.

9. Buat model SVM dan latih / Prediksi data testing

```
svm_model.fit(X_train_scaled, y_train)
```

```
SVC(C=1, random_state=42)
```

```
y_pred = svm_model.predict(X_test_scaled)
```

Penjelasan:

1. Model SVM dibuat menggunakan kernel **RBF (Radial Basis Function)** karena cocok untuk data non-linear. Parameter:

- `C=1`: mengontrol margin dan penalti kesalahan.
- `gamma='scale'`: otomatis menyesuaikan gamma berdasarkan jumlah fitur.

2.Model yang sudah dilatih digunakan untuk memprediksi label pada data uji (`X_test_scaled`).

10. Evaluasi performa model

```
print("\n===== HASIL EVALUASI MODEL SVM =====")
print("Akurasi Model : ", round(accuracy_score(y_test, y_pred) * 100, 2), "%")
print("\nConfusion Matrix:\n", confusion_matrix(y_test, y_pred))
print("\nClassification Report:\n", classification_report(y_test, y_pred))
```

```
===== HASIL EVALUASI MODEL SVM =====
Akurasi Model :  73.38 %

Confusion Matrix:
 [[82 17]
 [24 31]]

Classification Report:
              precision    recall  f1-score   support

           0       0.77      0.83      0.80        99
           1       0.65      0.56      0.60        55

    accuracy                           0.73       154
   macro avg       0.71      0.70      0.70       154
weighted avg       0.73      0.73      0.73       154
```

Penjelasan:

Bagian ini menampilkan hasil evaluasi:

- **Akurasi** → seberapa banyak prediksi benar.
- **Confusion Matrix** → tabel yang menunjukkan prediksi benar dan salah untuk tiap kelas.
- **Classification Report** → berisi *precision*, *recall*, dan *F1-score* untuk setiap kelas

Kesimpulan

1. Dataset dari Kaggle berhasil dieksplorasi dan digunakan untuk klasifikasi.
2. Model SVM dengan kernel RBF menghasilkan akurasi sekitar **79%** pada dataset diabetes.
3. Normalisasi fitur berperan penting dalam meningkatkan performa model.
4. SVM merupakan algoritma yang kuat untuk klasifikasi data numerik berukuran kecil hingga menengah.